# Facultatea de Informatica, Universitatea din Bucuresti

# Black-box Classification

Realizat de:

Paraschiv Andrei-Dumitru

Grupa 243

Prof. coord:

Cristina Madalina Noaica

# Cuprins

- 1. Despre mine
- 2. Cerinta Proiectului
- 3. Clasificatori antrenati
- 4. Random Forest Classifier
- 5. 3-Fold Cross Validation
- 6. Cod Sursa
  - 6.1 Data Loader
  - 6.2 Antrenare Clasificatori

## Despre mine

Nume: Paraschiv Andrei-Dumitru

LinkedIn: https://www.linkedin.com/in/andrei-paraschiv-a3561b178/

GitHub: https://github.com/pandreyy99/

#### Scurta Descriere:

"Student in anul 2 la Facultatea de Matematica si Informatica, specializarea Informatica, grupa 43, din cadrul Universitatii din Bucuresti.

Am studiat in cadrul facultatii Arhitectura sitemelor de calcul, Programare Procedurala, Concepte POO, Algoritmica si structuri de date, Analiza matematica, Statistica si Probabilistica, precum si diferite limbaje de programare(C/C++, Java, R, Python, etc.).

In prezent particip la o competitie de pe platforma Kaggle. "

## Cerinta Proiectului

Competitia este o provocare de tipul black-box in care trebuie sa antrenam un clasificator pentru a putea clasifica un set de 5.000 de date fara a sti ceea ce reprezinta, datele nefiind unele "human readable", avand la dispozitie si un set de 15.000 de astfel de date pentru antrenare, precum si etichetele corespunzatoare acestora.

Clasamentul in urma carora suntem clasificati se realizeaza in functie de scorul(acuratetea) clasificatorului antrenat in a recunoaste acel set de 5.000 de date, competitorii putand vizualiza in timpul competitiei doar un clasament provizoriu, bazat pe acuratetea obtinuta doar pe 20% din datele de testare, urmand ca la finalul competitiei sa fie disponibil si cel bazat pe restul datelor de testare.

Durata competitiei: 10.03.2019 19:04 UTC - 07.04.2019 23:59 UTC

### Regulile competitiei:

- 1. O echipa este formata dintr-un singur student.
- 2. Competitorii au voie doar cu un singur cont, conceptul de "multy-account" fiind interzis.
- 3. Este interzisa transmiterea datelor si a codului intre participanti, precum si fuziunea intre echipe.
- 4. Fiecare echipa poate incarca maxim 2 output-uri pe zi.

## Clasificatori antrenati

In cadrul competitiei m-am folosit de biblioteca scikit-learn din Python pentru a antrena diferiti clasificatori.

Pe parcursul competitiei am incercat diferiti clasificatori, precum:

- Diferite Clasificatori cu Vectori Suport(Support Vector Classifier aka SVC) din cadrul bibliotecii sklearn.svm
- Un clasificator bazat pe algoritmul de aflare a celor mai apropiati vecini(K-Nearest Neighbors aka KNN) din cadrul bibliotecii sklearn.neighbors
- Un clasificator de Regresie cu Cresterea bazata pe o componenta Nucleica(Kernel Ridge Regression aka KRR) din cadrul bibliotecii sklearn.kernel\_ridge
- Mai multe retele neurale de Perceptroni (Multi Layer Perceptrons aka MLP) din cadrul bibliotecii sklearn.neural\_network
- Un clasificator bazat pe algoritmul de Random Forest (Random Forest Clasifier aka RFC) din cadrul bibliotecii sklearn.ensemble
- Un clasificator de tip XGBoost (XGBClassifier aka XGBC) din cadrul bibliotecii xgboost

In urma rezultatelor obtinute si a unui proces de cercetare, am ales sa merg mai departe cu un clasificator ce se bazeaza pe algoritmul "Random Forest" (RFC) deoarece, chiar daca in urma impartirii datelor de antrenare in date de antrenare partiale si date de testare a avut o acuratete mai mica decat un clasificator cu vectori support, am inteles ca se descurca mai bine pe datele de testare care nu seamana atat de mult cu cele de antrenare, algoritmul din spate fiind unul probabilistic, si cum competitia este una de tip "black-box" si nu am putut sti cum arata datele fizic, am considerat ca merita incercat.

In prealabil am aplicat si un algoritm de determinare a Compenentei Principale(PCA – Principal Component Analysis) si am reusit sa reduc dimensiunea datelor de la 4096 de componente la doar 128, precum si un algoritm de cautare a unor parametric optimi(Grid Search) pentru clasificatorul antrenat(Random Forest Classifier), am normalizat datele si am creat un Data Loader ce foloseste biblioteca Pandas pentru a citi datele si pentru a le stoca astfel incat sa fie mai usor accesibile si sa nu trebuieasca sa le citesc de fiecare data.

## Random Forest Classifier

#### Parametri:

#### > n estimators:

- integer(implicit = 10 in versiunea 0.20 si 100 in versiunea 0.22)
- numarul de "arbori" folositi

#### > criterion:

- string(implicit = 'gini')
- functia de masurare a calitatii impartirii datelor
- specific "arborilor"
- 2 variante : 'gini' pentru Gini Impurity si 'entropy' pentru functia bazata pe cresterea informatiei

#### > max\_features :

- int, float, string or None, optional (default="auto")
- daca e int, atunci la fiecare split folosteste max\_features de features
- daca e float, atunci foloseste [max\_features \* n\_features] features pentru fiecare split
- daca e auto sau sqrt, atunci max\_features=sqrt(n\_features)
- daca e log2, atunci max\_features=log2(n\_features)
- daca e None, atunci max\_features = n\_features, <u>unde n\_features = #features cand e rulat fit()</u>

#### > max\_depth:

- integer or None, optional (default=None)
- Adâncimea maximă a "arborelui". Dacă e None, atunci nodurile sunt extinse până când toate frunzele sunt pure sau până când conțin mai puțin de min\_samples\_split mostre.

#### random state :

- int, RandomState instance or None, optional (default=None)
- daca e int, e folosit ca "samanta" (seed) pentru generatorul random
- daca e instanta, atunci random\_state e generatorul de numere random
- daca e None, atunci generatorul de numere random este intanta folosita pentru np.random

```
best_randomForestClassifier = RandomForestClassifier(criterion='entropy', max_depth=8, max_features='auto', n_estimators=100, random state=42)
```

## Procedura de tipul 3-fold cross-validation

### Acuratetea medie:

## Matricea de confuzie :

Regasiti rezultatele in fisierul"confusion\_matrix.txt" din cadrul arhivei

## Codul Sursa

#### Data Loader

```
.mport numpy as np
from sklearn import preprocessing
from sklearn.utils import shuffle
                 for rows in labels:
    self.labels = labels.to_numpy(dtype = 'int')
self.labels = self.labels.ravel()
```

```
# impartim setul de date in random% pentru antrenare si 1-random% pentru test
num_training_samples_per_class = int(random_distribution * len(data))
num_test_samples_per_class = len(data) - num_training_samples_per_class

# in setul de antrenare bagam datele cu indecsii 0:random*15000
train_data = self.data[0:num_training_samples_per_class]

# la fel si in etichetele datelor de intrare
train labels = self.labels[0:num training samples per class]

# in setul de test salvam restul datelelor din cel de antrenare
test data = self.data[num training samples per class:len(data)]
test labels = self.labels[num training samples per class:len(labels)]

# self.train_labels, self.train_data = train_labels, train_data
# self.test_labels, self.train_data = test_labels, test_data

# amestecam datele
self.train_data, self.train_labels = shuffle(train_data, train_labels)
self.test_data, self.test_labels = shuffle(test_data, test_labels))
self.num classes = max(np.max(self.train_labels), np.max(self.test_labels))
```

## Antrenarea Clasificatorilor

```
elif type == '12':
    # scaler = preprocessing.Normalizer() implicit 12
    scaler = preprocessing.Normalizer('12')
```

```
svm_classifier = svm.SVC(G=Cs[index], kernel=svm_type)
svm_classifier.fit(train_data, data_loader.train_labels)
clase_train[index] = get_accuracy(svm_classifier.predict(train_data), data_loader.train_labels)
clase_test[index] = get_accuracy(svm_classifier.predict(test_data), data_loader.test_labels)
```

```
for label in predicted_labels_xgbc:
    print(label , end=" ")
print('\n\n\n')
import csv

with open('sample_submission-XGBC.csv', 'w', newline='') as csv_file:
    writer = csv.writer(csv_file)
    # header = ["Id" , "Prediction"]
    writer.writerow(["Id", "Prediction"])
    for i in range(len(predicted labels xgbc)):
        list = []
        list.append(i + 1)
        list.append(predicted labels xgbc[i])
        writer.writerow(list)
```